

Classificação de Câncer de Mama em Imagens Histológicas

com CNNs, Transfer Learning e Inteligência Artificial Explicável (XAI)

Isabella Cristina da Silveira

Universidade Federal de Alfenas (UNIFAL-MG) · 2026

Redes Neurais Artificiais — UNIFAL-MG

Roteiro da Apresentação

01

Motivação e Contexto

Câncer de mama no Brasil · problema da caixa-preta

02

Dataset BreakHis

7.909 imagens histológicas · dataset brasileiro

03

Metodologia

Pré-processamento · CNN · ResNet18 · Ensemble

04

Resultados — Treinamento

Curvas de loss e acurácia · CNN vs ResNet18

05

Resultados — Avaliação Final

Métricas · Matrizes de Confusão · Comparação

06

Explicabilidade (XAI)

Grad-CAM · SHAP · Interpretação clínica

07

Conclusões e Próximos Passos

Resultados · Limitações · Trabalhos futuros

Motivação e Contexto

73.000+

novos casos/ano no Brasil (INCA, 2023)

2º tipo

de câncer mais frequente entre mulheres no Brasil

Diagnóstico histopatológico

= padrão ouro, mas demanda tempo e expertise de patologistas especializados

O Problema da "Caixa-Preta"

Alta Acurácia

modelos atingem 95–99%

Sem Interpretabilidade

médico não sabe o porquê

Baixa Confiança Clínica

difícil adoção na prática

Solução proposta: CNNs + Transfer Learning + XAI (Grad-CAM e SHAP)

Dataset — BreakHis

7.909

imagens histológicas RGB (700×460 px)

2 classes

Benigno (2.480 · 31,4%) · Maligno (5.429 · 68,6%)

4 aumentos

40× · 100× · 200× · 400×

82 pacientes

Dataset 100% brasileiro — UFPR + Lab. Paraná

Acesso público

<https://web.inf.ufpr.br/vri/databases/breakhis>




Imagem histológica benigna, BreakHis.




Imagem histológica maligna, BreakHis.

Distribuição das classes



Desbalanceamento → estratificação essencial no split

Divisão dos dados (seed = 42)

Treino 6.327 80%	Validação 791 10%	Teste 791 10%
------------------------	-------------------------	---------------------

Pré-processamento e Data Augmentation



Técnicas de Data Augmentation aplicadas no treino:

✓ Flip Horizontal

Válido: sem orientação canônica em histologia

✓ Rotação $\pm 15^\circ$

Simula variação de posicionamento da lâmina

✓ Flip Vertical

Células aparecem em qualquer direção


✓ ColorJitter

Brilho, contraste, saturação → variação de coloração H&E

Val e Teste: apenas Resize + Normalização (sem augmentation)

Arquiteturas dos Modelos

CNN Baseline (treinada do zero)




Inicialização: Kaiming Normal (Conv) · Xavier (Linear)

ResNet18 — Transfer Learning



Ensemble e Configuração de Treinamento

Ensemble — Soft Voting Ponderado



Configuração de Treinamento

Otimizador: Adam (lr = 1e-4)

Loss: CrossEntropyLoss

LR Scheduler: ReduceLROnPlateau (fator 0.5, paciência 3)

Early Stopping:

CNN: paciência 5 · ResNet18: paciência 7

Épocas:

CNN: 20 · ResNet18: 30 · (CPU apenas)

Resultados — CNN Baseline

Melhor Época

18 / 20

Val Acurácia

92,04%

Train Acurácia

89,60%

Train Loss

0,2535

Val Loss



0,2140

LR Final

5e-5 (reduzido na época 14)

Train Acc $\approx$ Val Acc $\rightarrow$
ausência de overfitting
significativo

Treinamento CNN — BreakHis



Resultados — ResNet18 com Transfer Learning

Melhor Época

26 / 30

Val Acurácia

99,12%

Train Acurácia

99,19%

Train Loss

0,0105


Val Loss

0,0663

LR Final

1.25e-5 (reduzido 3×)

Treinamento ResNet18 — BreakHis



Val Acc acima de 97% já na época 1 → poder do Transfer Learning!

Comparação dos Modelos

Desempenho no conjunto de teste (791 imagens)


Modelo	Acurácia	TP	TN	FP	FN
CNN	92,04%	511	217	31	32
ResNet18	99,12%	540	244	4	3
Ensemble	99,11%	540	243	5	3

Insight Principal

A ResNet18 superou a CNN em +7,1 p.p. de acurácia aproveitando pesos pré-treinados no ImageNet (1.2M imagens).

O Ensemble não superou a ResNet18 individualmente — indica que a CNN contribui com menos informação nova.


Comparação dos Modelos — BreakHis



Referência: Spanhol et al. (2016) obtiveram 80–85% com features handcrafted no mesmo dataset.

Matrizes de Confusão

CNN




Acurácia: 92,04%

FP: 31 FN: 32

Mais erros de classificação

ResNet18 ★




Acurácia: 99,12%

FP: 4 FN: 3

Erros mínimos!

Ensemble



Acurácia: 99,11%

FP: 5 FN: 3

Erros mínimos!

FP = benigno classificado como maligno · FN = maligno classificado como benigno (mais crítico clinicamente)


Explicabilidade — Grad-CAM

O que é o Grad-CAM?


- ① Passa a imagem pela rede
- ② Captura gradientes da última camada conv (layer4)
- ③ Pondera ativações pelos gradientes médios
- ④ Aplica ReLU + normaliza → heatmap [0,1]
- ⑤ Sobre põe à imagem com colormap JET

Vermelho = maior influência na predição

Azul = menor influência



Mapas de ativação Grad-CAM para amostra benigna do BreakHis. Regiões quentes (vermelho) indicam maior influência na predição de benigno.



Mapas de ativação Grad-CAM para amostra maligna do BreakHis. Regiões quentes (vermelho) indicam maior influência na predição de maligno.

Explicabilidade — SHAP

O que é o SHAP?

► Teoria dos jogos de Shapley

Cada pixel recebe valor de contribuição individual

► Background de 50 imagens


Distribuição de referência do dataset

► Sinal + ou –


(+) favorece maligno · (–) favorece benigno

► GradientExplainer

Eficiente para CNNs em PyTorch



Mapas SHAP para amostras do BreaKHis. Vermelho: contribuição positiva para maligno; Azul: contribuição benigna.



Mapas SHAP para amostras do BreaKHis. Vermelho: contribuição positiva para maligno; Azul: contribuição benigna.

Grad-CAM vs SHAP: perspectivas complementares

Interpretação Clínica dos Resultados XAI

O que o modelo aprendeu?

 Imagens MALIGNAS

- Alta densidade celular → ativação concentrada

- Bordas nucleares atípicas e irregulares

- Núcleos aumentados e hipercromáticos

- SHAP positivo (+) nessas regiões

 Imagens BENIGNAS

- Ativação distribuída uniformemente pelo tecido

- Estrutura tecidual regular e organizada

- Tecido conjuntivo (estroma) → SHAP negativo (–)

- Padrão celular bem delimitado

 Relevância Clínica

- Coerente com marcadores histológicos conhecidos

- Patologistas reconhecem os mesmos padrões

- XAI aumenta confiança na ferramenta

- Suporte à decisão, não substituição do médico

"A combinação Grad-CAM + SHAP oferece duas perspectivas complementares — global e pixel a pixel — aumentando a transparência do modelo." (Artigo, 2026)

Conclusões

01

Transfer Learning é superior

ResNet18 (99,12%) superou CNN do zero (92,04%) em +7,1 p.p., aproveitando pesos do ImageNet com 1.2M imagens.

02

Ensemble manteve desempenho

Soft Voting (CNN 40% + ResNet18 60%) obteve 99,11% — muito próximo da ResNet18 individual.

03

XAI agrega valor clínico

Grad-CAM e SHAP identificaram regiões clinicamente coerentes: alta densidade celular e bordas atípicas → maligno.

04

Resultado competitivo

ResNet18 com 99,12% posiciona-se entre os melhores resultados da literatura para o BreakHis.

Trabalhos futuros: stain normalization · EfficientNet / Vision Transformer · validação multi-institucional

Obrigada!

Isabella Cristina da Silveira

isabella.cristina@sou.unifal-mg.edu.br

UNIFAL-MG — Redes Neurais Artificiais · 2026

Referências

- INCA. Estimativa 2023.
- SPANHOL et al. IEEE Trans. Biomed. Eng., 2016.
- LITJENS et al. Med. Image Anal., 2017.
- SELVARAJU et al. Grad-CAM. ICCV, 2017.
- LUNDBERG & LEE. SHAP. NeurIPS, 2017.
- HAN et al. Sci. Reports, 2017.