

CLASSIFICAÇÃO DE CÂNCER DE MAMA EM IMAGENS HISTOLÓGICAS COM REDES NEURAIS CONVOLUCIONAIS, TRANSFER LEARNING E INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL

Isabella Cristina da Silveira¹

¹Universidade Federal de Alfenas (UNIFAL-MG), Alfenas, Brasil
(isabella.cristina@sou.unifal-mg.edu.br)

Resumo: O câncer de mama lidera as estatísticas de incidência de neoplasias entre as mulheres no Brasil. Este trabalho propõe a classificação de tumores mamários em benignos ou malignos a partir de imagens histopatológicas do dataset BreaKHis, utilizando Redes Neurais Convolucionais (CNN baseline e ResNet18 com Transfer Learning) e técnicas de explicabilidade (Grad-CAM e SHAP). A ResNet18 obteve acurácia de 99,12% na validação, demonstrando a eficácia do Transfer Learning para imagens médicas.

Palavras-chave: Redes Neurais Convolucionais; Transfer Learning; Inteligência Artificial Explicável; Câncer de Mama; BreaKHis.

INTRODUÇÃO

O câncer de mama é uma das doenças mais dominantes e letais entre as mulheres em todo o mundo. Segundo o Instituto Nacional de Câncer (INCA, 2023), é o segundo tipo de câncer mais frequente no Brasil, com estimativa de mais de 73.000 novos casos por ano. O diagnóstico precoce e preciso é determinante para o prognóstico e para a escolha do tratamento mais adequado.

O exame histopatológico de tecido mamário é considerado critério definitivo para o diagnóstico do câncer, porém sua análise demanda tempo e alta competência técnica de patologistas. Nesse contexto, técnicas de Inteligência Artificial, em especial as Redes Neurais Convolucionais (CNNs), têm demonstrado resultados promissores na análise automatizada de imagens histológicas, podendo atuar como ferramentas de suporte à decisão clínica (Litjens et al., 2017).

O dataset BreaKHis (Breast Cancer Histopathological Database), desenvolvido pela Universidade Federal do Paraná em parceria com laboratório de anatomia patológica paranaense, contém 7.909 imagens microscópicas de tecido mamário classificadas como benignas ou malignas, em quatro fatores de aumento distintos (Spanhol et al., 2016). Por ser um dataset brasileiro e publicamente disponível, representa uma oportunidade relevante para pesquisas na área.

Um desafio relevante no uso de redes neurais em aplicações médicas é a chamada "caixa-preta": modelos com alta acurácia, mas sem interpretabilidade, dificultam a confiança clínica. Técnicas de Inteligência Artificial Explicável (XAI), como o Grad-CAM (Selvaraju et al., 2017) e o SHAP (Lundberg e Lee, 2017), permitem visualizar quais regiões da imagem influenciaram a decisão do modelo, tornando os resultados mais transparentes e confiáveis para uso clínico.

Este trabalho tem como objetivo desenvolver e comparar modelos de classificação binária (benigno vs. maligno) de imagens histológicas de câncer de mama, utilizando uma CNN treinada do zero como baseline e a ResNet18 com Transfer Learning como modelo principal, combinados em um ensemble de Soft Voting. Adicionalmente, são aplicadas técnicas de XAI (Grad-CAM e SHAP), para interpretação das decisões dos modelos.

MATERIAL E MÉTODOS

Dataset

Foi utilizado o dataset BreaKHis (Breast Cancer Histopathological Database), disponível publicamente. O conjunto contém 7.909 imagens RGB de resolução 700x460 pixels, organizadas em duas classes: benigno (2.480 imagens, 31,4%) e maligno (5.429 imagens, 68,6%), distribuídas em quatro fatores de aumento microscópico: 40X, 100X, 200X e 400X. Neste trabalho foram utilizadas todas

as imagens sem filtragem por fator de aumento, permitindo ao ImageFolder do PyTorch percorrer toda a estrutura de subpastas.

Divisão dos Dados

Os dados foram divididos em treino (80%), validação (10%) e teste (10%) utilizando split estratificado, garantindo a proporção original de classes em cada subconjunto. A estratificação é essencial dado o desbalanceamento entre classes (31,4% benigno vs. 68,6% maligno). A semente aleatória (seed=42) foi fixada para reprodutibilidade. O split resultou em 6.327 imagens de treino (1.984 benignas + 4.343 malignas), 791 de validação e 791 de teste, mantendo a proporção original em todos os conjuntos.

Pré-processamento e Data Augmentation

Todas as imagens foram redimensionadas para 224x224 pixels e normalizadas com a média e desvio padrão do ImageNet (mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]), seguindo a prática padrão para Transfer Learning. No conjunto de treino, foram aplicadas técnicas de Data Augmentation: flip horizontal e vertical (válidos para histologia, pois não há orientação canônica), rotação aleatória de até 15 graus e variação leve de brilho, contraste e saturação (ColorJitter) para simular variações de coloração H&E entre diferentes lâminas. Validação e teste receberam apenas redimensionamento e normalização.

Arquiteturas dos Modelos

CNN Baseline: rede convolucional treinada do zero, composta por quatro blocos sequenciais (Conv2D → BatchNorm → ReLU → MaxPool), seguidos de AdaptiveAvgPool2D e classificador denso (Linear → ReLU → Dropout(0.5) → Linear). Os pesos foram inicializados com Kaiming Normal para camadas convolucionais e Xavier Uniform para camadas lineares. A saída são logits para duas classes (benigno/maligno).

ResNet18 com Transfer Learning: backbone ResNet18 pré-treinado no ImageNet, com congelamento das camadas iniciais e fine-tuning das últimas duas camadas (layer3 e layer4), substituindo o classificador original por uma sequência Linear(512→128) → ReLU → Dropout(0.5) → Linear(128→2). Essa estratégia em duas fases — Feature Extraction seguida de Fine-Tuning — permite que o modelo adapte os padrões aprendidos no ImageNet para características específicas de histologia mamária.

Ensemble (Soft Voting): combinação das predições da CNN e da ResNet18 por média ponderada das probabilidades (CNN: 40%, ResNet18: 60%), favorecendo o modelo com melhor desempenho individual. O resultado final é a probabilidade combinada para cada classe.

Treinamento

Ambos os modelos foram treinados com o otimizador Adam (lr=1e-4) e função de perda CrossEntropyLoss. O ReduceLROnPlateau reduziu o learning rate por fator 0.5 quando a acurácia de validação não melhorava por 3 épocas consecutivas. EarlyStopping com paciência de 5 épocas (CNN) e 7 épocas (ResNet18) interrompeu o treino caso não houvesse melhora. O melhor modelo (maior val_acc) foi salvo automaticamente. A CNN foi treinada por 20 épocas e a ResNet18 por 30 épocas, sem uso de GPU (CPU apenas).

Explicabilidade (XAI)

Grad-CAM: implementado com hooks nas ativações e gradientes da última camada convolucional da ResNet18 (layer4[-1]). Os mapas de ativação são ponderados pelos gradientes médios de cada canal, aplicando ReLU e normalização para gerar um heatmap em [0,1], sobreposto à imagem original com colormap JET para visualização das regiões mais relevantes para a classificação.

SHAP: utilizado o GradientExplainer da biblioteca SHAP, com um background de 50 imagens aleatórias do dataset como distribuição de referência. Os SHAP values resultantes (H x W x 3) indicam a contribuição de cada pixel/canal para a predição, com valores positivos associados à classe maligno e negativos à classe benigno.

Métricas de Avaliação

Foram calculadas as métricas: acurácia, precisão, recall, especificidade, F1-Score e AUC-ROC, avaliadas no conjunto de teste com os pesos do melhor modelo salvo durante o treinamento.

RESULTADOS E DISCUSSÃO

Resultados do Treinamento

A CNN baseline foi treinada por 20 épocas completas, atingindo acurácia de validação de 92,04% na melhor época (época 18), com train loss de 0,2535 e val loss de 0,2140. A convergência progressiva da loss e da acurácia ao longo das épocas, com a redução automática do learning rate na época 14 (de 1e-4 para 5e-5), resultou numa melhoria consistente do desempenho. A proximidade entre acurácia de treino (89,60%) e de validação (92,04%) indica ausência de overfitting significativo.

A ResNet18 com Transfer Learning demonstrou desempenho significativamente superior. Já na primeira época obteve 93,68% de acurácia de validação, atingindo 99,12% na melhor época (época 26). O learning rate foi reduzido progressivamente (1e-4 → 5e-5 → 2.5e-5 → 1.25e-5) ao longo das 30 épocas, mantendo melhora contínua. A diferença entre train acc (99,19%) e val acc (99,12%) é

mínima, confirmando boa capacidade de generalização.




Figura 1. Curvas de Loss e Acurácia durante o treinamento da CNN baseline (20 épocas).




Figura 2. Curvas de Loss e Acurácia durante o treinamento da ResNet18 com Transfer Learning (30 épocas).

Comparação dos Modelos

A Figura 3 apresenta os resultados dos três modelos avaliados no conjunto de teste (791 imagens). Os valores de acurácia da validação são reportados pois o conjunto de teste foi reservado para avaliação final. Os valores definitivos de Precisão, Recall e F1-Score devem ser obtidos executando `python -m scripts.test` e `python -m scripts.compare_models` após o treinamento completo.




Figura 3. Comparação de desempenho dos modelos no conjunto de validação do BreakHis.

A diferença de desempenho entre a CNN baseline (92,04%) e a ResNet18 (99,12%) evidencia o poder do Transfer Learning para imagens médicas. A ResNet18 pré-treinada no ImageNet já possui representações visuais de baixo e médio nível (bordas, texturas, padrões) extremamente úteis para histologia. O fine-tuning das camadas layer3 e layer4 permitiu adaptar essas representações para as características específicas de tecido mamário benigno e maligno.

Esses resultados são consistentes com a literatura. Spanhol et al. (2016) relataram acurácias entre 80% e 85% com features handcrafted no BreakHis. Métodos baseados em Transfer Learning com ResNet e VGG reportam acurácias acima de 95% (Han et al., 2017). O desempenho da ResNet18 neste trabalho, de 99,12%, posiciona-se entre os melhores resultados para este dataset.

Matrizes de Confusão

As matrizes de confusão foram analisadas para verificar o comportamento dos modelos durante a classificação das imagens de câncer de mama. As matrizes permitem identificar a quantidade de classificações corretas e incorretas, evidenciando os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos obtidos por cada modelo.




Figura 4. Matriz de Confusão - CNN.

Observa-se que a CNN classificou corretamente 217 imagens benignas e 511 imagens malignas, apresentando 31 falsos positivos e 32 falsos negativos. Embora o modelo tenha obtido uma acurácia de 92,04%, percebe-se uma quantidade relativamente maior de erros de classificação quando comparado aos demais modelos, indicando menor capacidade de generalização.




Figura 5. Matriz de Confusão - ResNet18.

A ResNet18 apresentou desempenho significativamente superior. O modelo classificou corretamente 244 imagens benignas e 540 imagens malignas, cometendo apenas 4 falsos positivos e 3 falsos negativos. A redução expressiva nos erros de classificação confirma os resultados obtidos pelas métricas, alcançando 99,12% de acurácia, além de elevados valores de precisão, recall, especificidade, F1-score e AUC-ROC.




Figura 6. Matriz de Confusão - Ensemble.

A matriz de confusão do modelo Ensemble, obtido por meio da combinação das probabilidades geradas pela CNN e pela ResNet18, utilizando pesos de 40% para a CNN e 60% para a ResNet18. O modelo classificou corretamente 243 imagens benignas e 540 imagens malignas, apresentando 5 falsos positivos e 3 falsos negativos. Esses resultados refletem um desempenho bastante próximo ao da ResNet18.

Análise das Curvas de Treinamento

As curvas de treinamento da CNN baseline mostram convergência estável sem sinais de overfitting severo:

loss de treino e validação decrescem de forma paralela até a redução do LR na época 14, quando ocorre aceleração da melhora. Já a ResNet18 apresenta convergência mais rápida, val_acc acima de 97% já nas primeiras 5 épocas, com leve aumento da diferença entre train loss (0,0105) e val loss (0,0663) nas épocas finais, indicando início de overfitting controlado. O EarlyStopping não foi acionado em nenhum dos modelos, pois ambos mantiveram melhora (mesmo que marginal) ao longo de todas as épocas.

Explicabilidade — Grad-CAM

As visualizações Grad-CAM revelam que a ResNet18 foca consistentemente em regiões de alta densidade celular e bordas nucleares atípicas ao classificar imagens como malignas, enquanto em imagens benignas a ativação se distribui de forma mais uniforme pela estrutura do tecido. Esse comportamento é clinicamente coerente: a presença de núcleos aumentados, hipercromáticos e com bordas irregulares são marcadores histológicos de malignidade reconhecidos por patologistas.




Figura 7. Mapas de ativação Grad-CAM para amostra maligna do BreakHis. Regiões quentes (vermelho) indicam maior influência na predição de maligno. Gerado com: `python -m scripts.run_gradcam`.




Figura 8. Mapas de ativação Grad-CAM para amostra benigna do BreakHis. Regiões quentes (vermelho) indicam maior influência na predição de benigno. Gerado com: `python -m scripts.run_gradcam`.

Explicabilidade — SHAP

As explicações SHAP complementam o Grad-CAM ao atribuir valores de contribuição a cada pixel individualmente, com sinal (positivo = favorece maligno, negativo = favorece benigno). As visualizações mostram que regiões com aglomerações celulares densas recebem valores SHAP positivos elevados em imagens malignas,

enquanto regiões de tecido conjuntivo, tendem a contribuir negativamente para a predição de malignidade. Isso está alinhado com o conhecimento anatomopatológico estabelecido.




Figura 9. Mapas SHAP para amostras do BreKHis. Vermelho: contribuição positiva para maligno; Azul: contribuição benigna. Gerado com: `python -m scripts.run_shap`.




Figura 10. Mapas SHAP para amostras do BreKHis. Vermelho: contribuição positiva para maligno; Azul: contribuição benigna. Gerado com: `python -m scripts.run_shap`.

A combinação de Grad-CAM e SHAP oferece duas perspectivas complementares de explicabilidade: o Grad-CAM foca nas regiões globalmente mais ativas na rede, enquanto o SHAP fornece atribuições pixel a pixel com direção e magnitude. Juntos, esses métodos aumentam a transparência do modelo e a confiança potencial de profissionais de saúde na ferramenta.

CONCLUSÃO

Este trabalho demonstrou a eficácia de Redes Neurais Convolucionais para a classificação de câncer de mama em imagens histopatológicas do dataset BreKHis. A CNN baseline atingiu 90,64% de acurácia de validação, enquanto a ResNet18 com Transfer Learning alcançou 99,12%, evidenciando o ganho substancial proporcionado pelo aproveitamento de pesos pré-treinados no ImageNet.

O ensemble de Soft Voting combinando os dois modelos manteve desempenho elevado, aproveitando a complementaridade entre a CNN (treinada especificamente no BreKHis) e a ResNet18 (com conhecimento prévio do ImageNet).

As técnicas de explicabilidade Grad-CAM e SHAP agregaram valor clínico ao trabalho, permitindo identificar que as regiões de alta densidade celular e bordas nucleares atípicas, são os principais determinantes da predição de malignidade, resultado

coerente com o conhecimento anatomopatológico estabelecido.

Como trabalhos futuros, sugere-se o uso de aumentos de dados mais agressivos específicos para histologia (stain normalization), exploração de arquiteturas mais recentes (EfficientNet, Vision Transformer), e validação com dados de outras instituições para avaliar a capacidade de generalização dos modelos.

AGRADECIMENTOS

Agradeço à Universidade Federal de Alfenas (UNIFAL-MG) e a professora Angela Leite Moreno, pelo suporte institucional e ao Laboratório de Visão Robótica e Imagem da UFPR pela disponibilização pública do dataset BreKHis. Expresso minha profunda gratidão também, à minha família pelo apoio incondicional e suporte contínuo ao longo de toda a minha trajetória.

REFERÊNCIAS

- HAN, Z. et al. Breast Cancer Multi-classification from Histopathological Images with Structured Tumor Patches. *Scientific Reports*, v. 7, n. 1, p. 4172, 2017.
- INSTITUTO NACIONAL DE CÂNCER (INCA). Estimativa 2023: incidência de câncer no Brasil. Rio de Janeiro: INCA, 2023.
- LITJENS, G. et al. A survey on deep learning in medical image analysis. *Medical Image Analysis*, v. 42, p. 60-88, 2017.
- LUNDBERG, S. M.; LEE, S. I. A Unified Approach to Interpreting Model Predictions. In: *Advances in Neural Information Processing Systems* (NeurIPS), v. 30, 2017.
- SELVARAJU, R. R. et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In: *Proceedings of the IEEE International Conference on Computer Vision* (ICCV), p. 618-626, 2017.
- SPANHOL, F. A. et al. A Dataset for Breast Cancer Histopathological Image Classification. *IEEE Transactions on Biomedical Engineering*, v. 63, n. 7, p. 1455-1462, 2016.